

Desafio 16 – Risco de Crédito

Grupo 16 | Classificação Binária | Domínio Financeiro

RA	Alunos
2040669	Renan Gonçalves Rodrigues
2095896	Sofhia Kobor Dias

Este relatório apresenta o desenvolvimento completo do modelo preditivo de risco de crédito para o Desafio 16, utilizando o German Credit Dataset (Kaggle: uciml/german-credit). O objetivo é classificar solicitantes de crédito como **bom risco** (good) ou **mau risco** (bad), apoiando decisões de concessão de crédito em instituições financeiras.

Dataset	German Credit (Kaggle)
Amostras	1.000 registros
Variável alvo	Risk (good / bad)
Distribuição	70,5% good 29,5% bad
Entrega	19 de abril de 2026

Etapa 1 – Análise Exploratória (EDA)

1.1 Distribuição da Variável Alvo

O dataset apresenta desbalanceamento moderado: 70,5% das amostras são bons pagadores e 29,5% são maus pagadores. Esse nível de desbalanceamento é aceitável para treino direto com métricas adequadas (AUC-ROC e F1), sem necessidade de oversampling.




Figura 1 – Distribuição absoluta e proporcional do risco de crédito.

1.2 Variáveis Numéricas

As distribuições de **Age**, **Credit amount** e **Duration** revelam padrões relevantes: solicitantes com maior valor de crédito e prazos mais longos concentram-se proporcionalmente mais na classe de mau risco. A variável Age apresenta distribuição mais uniforme, com leve vantagem de bons pagadores nas faixas intermediárias.




Figura 2 – Histogramas das variáveis numéricas segmentados por classe de risco.

1.3 Variáveis Categóricas e Contas Financeiras

A análise da taxa de inadimplência por categoria mostra que **contas poupança sem saldo** (none/little) e **contas correntes sem reserva** estão fortemente associadas ao mau risco. Entre as variáveis nominais, o tipo de moradia e o propósito do crédito apresentam variações relevantes na taxa de inadimplência.




Figura 3 – Taxa de inadimplência por variável categórica

Etapa 2 – Pré-processamento

Os dados foram tratados seguindo critérios que preservam a semântica financeira das variáveis. Os valores ausentes em Saving accounts e Checking account foram substituídos pela categoria "none", interpretando a ausência de registro como ausência de conta - decisão coerente com o domínio de crédito.

As variáveis de conta foram codificadas de forma ordinal (none=0 até rich=4), preservando a hierarquia de capacidade financeira. As variáveis nominais Sex, Housing e Purpose receberam LabelEncoder, adequado dada a baixa cardinalidade. A variável alvo foi binarizada: 1 = good, 0 = bad.

A normalização com StandardScaler foi aplicada apenas nas variáveis numéricas (Age, Credit amount, Duration), com fit exclusivo no conjunto de treino para evitar data leakage. A divisão dos dados seguiu proporção 70/15/15 (treino/validação/teste) com Stratified split, garantindo que a proporção original de 70,5% / 29,5% fosse mantida em todos os subconjuntos.

Etapa	Detalhe
Valores Missing	Saving accounts e Checking account: NaN → categoria "none" (sem cont)
Encoding Ordinal	none=0, little=1, moderate=2, quite rich=3, rich=4
Encoding Nominal	LabelEncoder para Sex, Housing e Purpose
Target	1 = bom pagador (good), 0 = mau pagador (bad)
Normalização	StandardScaler nas variáveis numéricas (fit apenas no treino)
Divisão	70% treino / 15% validação / 15% teste – Stratified split

Etapa 3 – Comparação de Classificadores

Foram treinados três classificadores com validação cruzada Stratified K-Fold (k=5) no conjunto de desenvolvimento (treino + validação) e avaliação final no holdout de teste. A métrica principal é o

AUC-ROC, por sua robustez frente ao desbalanceamento e por medir a capacidade discriminativa geral do modelo.

3.1 Tabela de Métricas

Modelo	Acurácia	Precisão	Recall	F1-Score	AUC-ROC	AUC-CV
Logistic Regression	0.7667	0.7795	0.9340	0.8498	0.7903	0.7477 ± 0.025
Random Forest	0.7667	0.7795	0.9340	0.8498	0.8012	0.7392 ± 0.022
Gradient Boosting	0.7733	0.7951	0.9151	0.8509	0.7781	0.7072 ± 0.030

* Linha destacada = melhor AUC-ROC no conjunto de teste.

3.2 Matrizes de Confusão




Figura 4 – Matrizes de confusão dos três modelos no conjunto de teste.

3.3 Curvas ROC e K-Fold




Figura 6 – Curvas ROC (teste) e boxplot AUC por fold (K-Fold, k=5)

Etapa 4 – Análise Comparativa

4.1 Desempenho por AUC

O **Random Forest** obteve o maior AUC-ROC no conjunto de teste (**0.8012**), seguido de Logistic Regression (0.7903) e Gradient Boosting (0.7781). Na validação cruzada, a Logistic Regression apresentou AUC-CV superior (0.7477), indicando menor variância entre os folds. O Gradient Boosting, apesar de ter o maior F1-Score (0.8509), apresentou maior instabilidade na validação cruzada (desvio 0.030).

Critério	Melhor Modelo	Valor
AUC-ROC (teste)	Random Forest	0.8012
AUC-CV (k=5)	Logistic Regression	0.7477 ± 0.025
F1-Score	Gradient Boosting	0.8509
Estabilidade (menor desvio CV)	Random Forest	± 0.022

4.2 Feature Importance

Figura 7 – Importância das variáveis para cada modelo (vermelho = mais relevante).

Os três modelos convergem nos fatores mais preditivos: **Checking account** (conta corrente), **Duration** (prazo) e **Credit amount** (valor do crédito) lideram em todos eles. **Saving accounts** (poupança) e **Age** completam o top-5. Esses resultados são consistentes com a literatura de risco de crédito: fluxo de caixa corrente e capacidade de pagamento são os melhores indicadores de inadimplência.

Aspecto	Observação
Viés de gênero	Variável Sex pode gerar discriminação; avaliar impacto regulatório (LGPD/BC) an
Custo assimétrico	FN (aprovar inadimplente) = perda financeira; FP (recusar bom pagador) = dano
Explicabilidade	Logistic Regression é auditável nativamente. RF e GB requerem SHAP/LIME para

4.3 Discussão de Negócio e Ética

Fator	Impacto	Lógica de Negócio
Conta corrente	Alto	Maior saldo -> menor risco de inadimplência
Duração do crédito	Moderado	Prazos longos aumentam a exposição ao risco
Valor do crédito	Moderado	Créditos altos exigem maior capacidade de pagamento
Conta poupança	Alto	Reservas indicam disciplina financeira
Idade	Baixo	Jovens têm menor historico; idosos menor renda futura
Moradia	Baixo	Proprietários mostram maior estabilidade

Conclusão

O **Random Forest** é o modelo recomendado para produção, com AUC-ROC de 0.8012 no conjunto de teste e menor desvio padrão na validação cruzada (± 0.022). Os fatores mais determinantes são: saldo em conta corrente, prazo e valor do crédito — alinhados com a lógica financeira e com a literatura de credit scoring. Para uso em ambiente regulado, recomenda-se calibrar o threshold de decisão conforme a matriz de custos do negócio e aplicar SHAP para explicabilidade das predições individuais.

Entregáveis: notebook.ipynb (código completo) | relatorio_desafio16.pdf