

# Desafio 16 – Risco de Crédito

Grupo 16 | Classificação Binária | Domínio Financeiro  
P2 – Versão Corrigida e Atualizada

| RA      | Aluno                     |
|---------|---------------------------|
| 2040669 | Renan Gonçalves Rodrigues |
| 2095896 | Sofhia Kobor Dias         |

|               |                                                                   |
|---------------|-------------------------------------------------------------------|
| Dataset       | German Credit Data (Kaggle – kabure/german-credit-data-with-risk) |
| Amostras      | 1.000 registros                                                   |
| Variável alvo | Risk — bad = 1 (classe positiva), good = 0                        |
| Distribuição  | 70% good   30% bad                                                |
| Versão        | P2 – Notebook re-executado e relatório atualizado                 |

Este relatório documenta o desenvolvimento completo do modelo preditivo de risco de crédito para o Desafio 16, utilizando o German Credit Dataset disponível no Kaggle. O objetivo central é classificar solicitantes como **bom pagador** (good) ou **mau pagador** (bad), apoiando decisões de concessão de crédito em instituições financeiras. Esta é a versão P2, que incorpora todas as correções metodológicas identificadas na devolutiva da P1.

## Correções Aplicadas em Relação à P1

Após a avaliação da P1, três problemas metodológicos foram identificados e corrigidos nesta versão:

| Problema (P1)                                                               | Correção (P2)                                                                                                                                                                       |
|-----------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| LabelEncoder em variáveis nominais (Sex, Housing, Purpose)                  | Substituído por OneHotEncoder via ColumnTransformer. Variáveis nominais não possuem ordem natural — o LabelEncoder atribui números arbitrários que induziram hierarquia artificial. |
| StandardScaler aplicado sobre colunas ordinais já codificadas como inteiros | Scaler aplicado apenas sobre numéricas contínuas (Age, Credit amount, Duration). Normalizar ordinais destrói a interpretabilidade ordinal e pode distorcer o aprendizado.           |
| Métricas reportadas para a classe good (majoritária - foco invertido)       | Métricas recalculadas com pos_label=1 (bad). O objetivo do negócio é detectar inadimplentes; avaliamos Precisão, Recall e F1 da classe de risco.                                    |
| Inconsistência entre notebook e relatório                                   | Notebook re-executado do zero com resultados finais reais. Relatório atualizado conforme saídas do notebook.                                                                        |
| Modelo final não salvo                                                      | Pipeline completo salvo em model/modelo_final.joblib (pré-processamento + GradientBoosting encadeados via sklearn.Pipeline).                                                        |

## Etapa 1 – Análise Exploratória (EDA)

### 1.1 Distribuição da Variável Alvo

O dataset apresenta desbalanceamento moderado: **70% das amostras são bons pagadores e 30% são maus pagadores**. Esse desequilíbrio não inviabiliza o treinamento direto, mas exige cuidado na escolha das métricas

de avaliação. Por isso, adotamos o **AUC-ROC como métrica principal**, por ser robusta ao desbalanceamento, e reportamos todas as métricas secundárias (Precisão, Recall, F1) focadas na **classe bad**, que representa o risco real de negócio.




Figura 1 – Gráfico de distribuição da variável alvo.

## 1.2 Variáveis Numéricas

As distribuições de Age, Credit amount e Duration, segmentadas por classe de risco, revelam padrões relevantes para o modelo. Créditos de **prazo mais longo** concentram proporcionalmente mais casos de inadimplência. Prazos maiores aumentam a exposição ao risco ao longo do tempo. Da mesma forma, **valores de crédito mais altos** estão associados à classe bad. A variável Age apresenta distribuição mais uniforme, com leve concentração de inadimplência na faixa de 20 a 30 anos, o que pode refletir menor histórico de crédito nessa população.

## 1.3 Taxa de Inadimplência por Variável Categórica

A análise da taxa de inadimplência por categoria revela padrões importantes. Em relação à **finalidade do crédito**, “vacation/others” (42%) e “education” (39%) concentram as maiores taxas — provavelmente porque são créditos sem retorno financeiro direto. Quanto à **moradia**, solicitantes sem moradia própria (“free”, 41%) apresentam maior risco. A diferença por **gênero** (female: 35% vs. male: 28%) foi observada, mas deve ser tratada com cautela ética (ver seção 4.3).




Figura 2 – Taxa de inadimplência por variável categórica

## Etapa 2 – Pré-processamento

O pré-processamento foi completamente redesenhado na P2, com um pipeline tipado por variável que corrige os problemas identificados na versão anterior. A lógica central é tratar cada tipo de variável com a transformação adequada à sua natureza, evitando distorções que prejudicam o aprendizado dos modelos.

## 2.1 Tratamento de Valores Ausentes

As colunas Saving accounts (183 valores ausentes) e Checking account (394 valores ausentes) tiveram seus NaN substituídos pela categoria "none". Essa decisão é semanticamente correta: a ausência de registro representa a ausência da conta e não um dado faltante aleatório.

## 2.2 Codificação das Variáveis

| Tipo                | Colunas                           | Transformação                 | Justificativa                                                    |
|---------------------|-----------------------------------|-------------------------------|------------------------------------------------------------------|
| Numéricas contínuas | Age, Credit amount, Duration      | StandardScaler                | Normaliza magnitude para comparação justa entre features         |
| Ordinais            | Saving accounts, Checking account | OrdinalEncoder (ordem manual) | Preserva hierarquia financeira: none < little < moderate < rich  |
| Nominais            | Sex, Housing, Purpose             | OneHotEncoder (P2: corrigido) | Sem ordem natural — colunas binárias independentes por categoria |
| Ordinal numérica    | Job                               | Passthrough (0 a 3)           | Já está em escala ordinal natural; não requer transformação      |

### Correção P2 — OneHotEncoder:

Na P1, as variáveis nominais Sex, Housing e Purpose foram codificadas com LabelEncoder, que atribui inteiros arbitrários (0, 1, 2...) e induz o modelo a interpretar uma ordem hierárquica inexistente. Por exemplo, "business"=0 e "education"=2 não significa que educação vale o dobro de business. Na P2, o OneHotEncoder cria uma coluna binária independente para cada categoria, eliminando essa distorção.

## 2.3 Divisão dos Dados

Os dados foram divididos na proporção **70% treino / 15% validação / 15% teste**, utilizando estratificação em todas as etapas para garantir que a proporção de inadimplentes fosse mantida em cada subconjunto. O pré-processamento foi ajustado (*fit*) exclusivamente no conjunto de treino e aplicado (*transform*) nos demais, evitando **data leakage**.

| Conjunto  | Amostras | Proporção bad |
|-----------|----------|---------------|
| Treino    | 700      | 30,00%        |
| Validação | 150      | 30,00%        |
| Teste     | 150      | 30,00%        |

## Etapa 3 – Comparação de Classificadores

Foram treinados três classificadores: **Logistic Regression**, **Random Forest** e **Gradient Boosting**. A validação cruzada foi feita com **Stratified K-Fold (k=5)** no conjunto de desenvolvimento (treino + validação). A avaliação final foi realizada no holdout de teste, que os modelos não viram durante o treinamento.

### Correção P2 — Classe positiva nas métricas:

Na P1, o target estava codificado como good=1, o que fazia com que Precisão, Recall e F1 medissem o desempenho na classe majoritária. Isso distorcia a avaliação. Na P2, recodificamos para **bad=1** (classe positiva de interesse de negócio). As métricas agora refletem a capacidade real do modelo de identificar inadimplentes.

### 3.1 Resultados da Validação Cruzada

Antes de avaliar no teste, os modelos foram comparados via AUC-ROC na validação cruzada:

| Modelo              | AUC-CV (média) | Desvio padrão |
|---------------------|----------------|---------------|
| Logistic Regression | 0.6988         | ± 0.0143      |
| Random Forest       | 0.7645         | ± 0.0307      |
| Gradient Boosting   | 0.7521         | ± 0.0409      |

### 3.2 Tabela Completa de Métricas (Conjunto de Teste)

Todas as métricas abaixo são calculadas para a **classe bad (pos\_label=1)**, que é a classe de interesse do negócio:

| Modelo                     | Acurácia      | Precisão      | Recall (bad)  | F1 (bad)      | AUC-ROC       | AUC-CV                |
|----------------------------|---------------|---------------|---------------|---------------|---------------|-----------------------|
| Logistic Regression        | 0.7067        | 0.5263        | 0.2222        | 0.3125        | 0.6459        | 0.6988 ± 0.014        |
| Random Forest              | 0.7533        | 0.7222        | 0.2889        | 0.4127        | 0.7562        | 0.7645 ± 0.031        |
| <b>Gradient Boosting ✓</b> | <b>0.7267</b> | <b>0.5476</b> | <b>0.5111</b> | <b>0.5287</b> | <b>0.7192</b> | <b>0.7521 ± 0.041</b> |

✓ *Modelo final selecionado. Métricas de Precisão, Recall e F1 referem-se à classe bad (inadimplente).*

### 3.3 Matrizes de Confusão

As matrizes de confusão revelam como cada modelo distribui seus erros. No domínio de crédito, os dois tipos de erro têm custos muito diferentes: um **Falso Negativo** (inadimplente classificado como bom pagador) representa aprovação de crédito para quem não vai pagar — perda financeira direta. Um **Falso Positivo** (bom pagador rejeitado) representa dano ao cliente e perda de receita.




Figura 3 – Matrizes de confusão dos três modelos.

O Gradient Boosting apresentou apenas **22 Falsos Negativos**, contra 35 da Logistic Regression e 32 do Random Forest — confirmando sua superioridade na detecção de inadimplentes. Embora tenha mais Falsos Positivos (19), esse trade-off é aceitável dado o custo maior do FN no domínio financeiro.

### 3.4 Curvas ROC e Validação Cruzada

A curva ROC mostra a relação entre a Taxa de Verdadeiros Positivos (TPR/Recall) e a Taxa de Falsos Positivos (FPR). Quanto mais próxima do canto superior esquerdo, melhor o modelo. O Random Forest apresenta a maior AUC no teste (0.756), mas o Gradient Boosting opera em um ponto mais favorável da curva para o objetivo de negócio. O boxplot confirma estabilidade similar entre RF e GBM na validação cruzada.




Figura 4 – Curvas ROC e boxplot AUC-ROC por fold

3.5 Classification Report — Modelo Final

O relatório detalhado de classificação do Gradient Boosting no conjunto de teste:

| Classe       | Precisão | Recall | F1-Score | Suporte |
|--------------|----------|--------|----------|---------|
| good (0)     | 0.80     | 0.82   | 0.81     | 105     |
| bad (1)      | 0.55     | 0.51   | 0.53     | 45      |
| accuracy     |          |        | 0.73     | 150     |
| macro avg    | 0.67     | 0.67   | 0.67     | 150     |
| weighted avg | 0.72     | 0.73   | 0.72     | 150     |

Etapa 4 – Análise Comparativa

4.1 Escolha do Modelo Final

O **Gradient Boosting** foi selecionado como modelo final. A decisão pode parecer contraintuitiva à primeira vista, já que o Random Forest apresenta AUC-ROC ligeiramente maior no teste (0.756 vs. 0.719). No entanto, a diferença de 4 pontos percentuais em AUC é compensada por um ganho de **22 pontos percentuais em Recall(bad)** — que é a métrica que diretamente mensura a capacidade de identificar inadimplentes.

| Critério        | Random Forest | Gradient Boosting | Vantagem     |
|-----------------|---------------|-------------------|--------------|
| AUC-ROC (teste) | 0.7562        | 0.7192            | RF (+4pp)    |
| Recall(bad)     | 0.2889        | 0.5111            | GBM (+22pp)  |
| F1(bad)         | 0.4127        | 0.5287            | GBM (+12pp)  |
| FN no teste     | 32            | 22                | GBM (−10 FN) |
| AUC-CV          | 0.7645        | 0.7521            | RF (+1pp)    |

Justificativa de negócio:

No domínio de crédito, aprovar um inadimplente (Falso Negativo) gera perda financeira direta e imediata para a instituição. Rejeitar um bom pagador (Falso Positivo) gera dano ao cliente e perda de receita potencial, mas é reversível. Por isso, **maximizar o Recall da classe bad é prioritário**. O Gradient Boosting erra apenas 49% dos inadimplentes, contra 71% do Random Forest — uma diferença operacionalmente significativa.

4.2 Feature Importance




Figura 5 – Feature importance dos três modelos

Os três modelos convergem nos fatores mais preditivos. O **Checking account** (conta corrente) lidera no Random Forest, enquanto o **Credit amount** domina no Gradient Boosting. A **Duration** é consistentemente relevante nos três modelos. Esses resultados são coerentes com a teoria de credit scoring: liquidez corrente e capacidade de endividamento são os melhores preditores de inadimplência.

| Fator                             | Impacto       | Lógica de Negócio                                   |
|-----------------------------------|---------------|-----------------------------------------------------|
| Checking account (conta corrente) | Alto          | Maior saldo corrente → menor risco de inadimplência |
| Credit amount (valor do crédito)  | Alto          | Créditos altos exigem maior capacidade de pagamento |
| Duration (prazo)                  | Alto          | Prazos longos aumentam a exposição ao risco         |
| Age (idade)                       | Moderado      | Jovens têm menor histórico de crédito               |
| Saving accounts (poupança)        | Moderado      | Reservas indicam disciplina financeira              |
| Purpose (finalidade)              | Moderado      | Educação e férias concentram maior risco histórico  |
| Housing (moradia)                 | Baixo         | Proprietários mostram maior estabilidade financeira |
| Sex (gênero)                      | Baixo / Ético | Observado, mas requer cautela ética (ver seção 4.3) |

4.3 Discussão de Negócio e Ética

Além do desempenho técnico, qualquer modelo de risco de crédito precisa ser avaliado sob a perspectiva de seus impactos reais sobre as pessoas. Identificamos três pontos críticos:

- **Viés de gênero (Sex):** A variável Sex foi incluída por razões acadêmicas, mas sua aplicação em produção é problemática. A LGPD e as normas do Banco Central restringem o uso de dados pessoais sensíveis em decisões automatizadas de crédito. Antes de qualquer uso em produção, seria necessário avaliar o impacto diferencial por grupo.
- **Custo assimétrico dos erros:** O threshold padrão de 0,50 pode não ser o ideal para o negócio. Usando a curva ROC, é possível identificar o ponto operacional que equilibra os dois tipos de erro conforme a política de risco da instituição.
- **Explicabilidade (LGPD art. 20):** Decisões automatizadas que afetam interesses de pessoas físicas precisam ser explicáveis. Para uso em ambiente regulado, recomenda-se a aplicação de SHAP ou LIME para gerar explicações individuais de cada predição. Também é importante monitorar data drift periodicamente.

## Etapa 5 – Salvamento do Modelo Final

O modelo final foi salvo como um **pipeline completo** usando a biblioteca joblib. O arquivo `modelo_final.joblib` contém tanto o pré-processamento (ColumnTransformer com OHE, OrdinalEncoder e StandardScaler) quanto o classificador (GradientBoostingClassifier), encadeados em um único objeto Pipeline do scikit-learn. Essa abordagem garante que a aplicação Streamlit aplique exatamente as mesmas transformações usadas durante o treino.

| Arquivo                                | Conteúdo                                                                |
|----------------------------------------|-------------------------------------------------------------------------|
| <code>model/modelo_final.joblib</code> | Pipeline completo: ColumnTransformer + GradientBoostingClassifier       |
| <code>model/feature_info.joblib</code> | Metadados das features: listas de colunas por tipo, categorias ordinais |

*O pipeline foi verificado após o carregamento: AUC verificado = 0.7192, F1(bad) verificado = 0.5287. As predições do arquivo salvo são idênticas às geradas durante o treinamento.*

## Conclusão

Este projeto desenvolveu um classificador de risco de crédito capaz de identificar corretamente **51% dos inadimplentes** no conjunto de teste, representando uma melhoria substancial em relação à versão anterior, onde as métricas estavam sendo calculadas para a classe errada. A escolha pelo Gradient Boosting reflete uma decisão orientada ao negócio: mesmo com AUC ligeiramente inferior ao Random Forest, seu Recall(bad) de 0,51 contra 0,29 representa 10 inadimplentes a menos aprovados incorretamente no conjunto de teste.

As correções da P2 endereçam problemas metodológicos reais: o uso de OneHotEncoder elimina a hierarquia artificial nas variáveis nominais; o foco nas métricas da classe bad alinha a avaliação ao objetivo de negócio; e o pipeline encadeado garante consistência entre treinamento e inferência.

Para uso em produção, recomendamos: calibrar o threshold via curva ROC; implementar SHAP para explicabilidade; remover ou auditar a variável Sex para conformidade com LGPD; e estabelecer monitoramento contínuo para detectar data drift.

Entregáveis: `notebook_atualizado.ipynb` | `relatorio_atualizado.pdf` | `app.py` | `model/modelo_final.joblib`